

Mengungkap Penipuan Pembayaran dalam Transaksi Bank dengan Pendekatan CNN: Meningkatkan Keamanan Transaksi

Zhuliana Melva Rey¹, Dian Rospita², Fayza Aulia³, Rismiyati⁴

¹Fakultas Sains dan Matematika, Universitas Diponegoro, Semarang, 50275, email: zhuliana@students.undip.ac.id

²Fakultas Sains dan Matematika, Universitas Diponegoro, Semarang, 50275, email: dianrospita@students.undip.ac.id

³Fakultas Sains dan Matematika, Universitas Diponegoro, Semarang, 50275, email: fayzaaulia8@students.undip.ac.id

⁴Fakultas Sains dan Matematika, Universitas Diponegoro, Semarang, 50275, email: rismiyati@lecturer.undip.ac.id

Corresponding Author: Zhuliana Melva Rey

INTISARI — Penelitian ini menggunakan *Convolutional Neural Network* (CNN) untuk menemukan *screenshot* bukti pembayaran palsu untuk mengatasi risiko penipuan dalam transaksi perbankan digital. Meskipun kemajuan teknologi telah membuat transaksi perbankan lebih mudah, penipuan semakin canggih dan lebih sulit ditemukan. Penipuan disebabkan oleh literasi digital yang buruk, penggunaan *mobile banking* yang terbatas, dan notifikasi SMS bank yang terlambat. Fokus penelitian ini adalah Bank BRI. Tujuan dari penelitian ini adalah untuk meningkatkan keamanan transaksi, menemukan tanda-tanda pembayaran palsu, dan mengembangkan metode inovatif untuk mendeteksi penipuan pembayaran. CNN dalam deteksi *screenshot* bukti pembayaran dalam penelitian ini mendapatkan akurasi yang tergolong rendah, yakni 56% saja. Tahap *preprocessing* diharapkan bisa lebih dikembangkan untuk meningkatkan akurasi CNN dalam deteksi *screenshot* bukti pembayaran.

KATA KUNCI — CNN, *Screenshot* Bukti Pembayaran, Bank BRI, Akurasi CNN, Preprocessing

I. PENDAHULUAN

Kemajuan teknologi telah membuat transaksi perbankan di era digital lebih mudah dan efektif. Namun, ancaman penipuan yang semakin canggih dan sulit untuk dideteksi muncul bersama dengan kemudahan tersebut. Banyak orang telah menjadi korban penipuan melalui *screenshot* bukti pembayaran palsu yang merugikan mereka secara finansial dan merusak kepercayaan sistem perbankan. Penipu biasanya membuat gambar palsu yang terlihat seperti bukti pembayaran yang sebenarnya dengan tujuan untuk meyakinkan orang demi mendapat keuntungan.

Laporan dari Kementerian Komunikasi dan Informatika Indonesia menunjukkan bahwa penipuan dengan modus *screenshot* bukti pembayaran palsu telah terjadi lebih dari 10.000 kali pada tahun 2022, menunjukkan bahwa penipuan ini masih menjadi ancaman serius bagi masyarakat. Penelitian yang dilakukan oleh Awaliah [1] menemukan bahwa penipuan yang menggunakan *screenshot* bukti pembayaran semakin meningkat dan mengakibatkan kerugian finansial yang sangat besar. Akibatnya, perlu dilakukan tindakan untuk meningkatkan keamanan transaksi dan memudahkan identifikasi *screenshot* bukti pembayaran palsu.

Kekurangan literasi digital adalah salah satu faktor yang menyebabkan orang menjadi korban penipuan, terutama bagi orang tua. Meskipun *mobile banking* sudah populer, banyak orang tua yang masih bingung bagaimana menggunakannya. Mereka tidak terbiasa dengan antarmuka aplikasi atau mungkin tidak memahami tanda-tanda penipuan. Menurut penelitian yang dilakukan oleh Nisa dkk [2], karena kurangnya literasi digital, kelompok orang tua sering kali menjadi sasaran penipuan. Mereka lebih rentan terhadap penipuan karena mereka cenderung kurang berhati-hati saat memverifikasi *screenshot* bukti pembayaran. Oleh karena itu, penting untuk mengembangkan solusi yang dapat membantu mereka menemukan *screenshot* bukti pembayaran palsu dan menghindari penipuan dalam transaksi perbankan.

Banyak orang di Indonesia belum benar-benar beralih ke layanan perbankan digital seperti perbankan *mobile*. Banyak

orang lebih suka menggunakan SMS untuk mengetahui berapa banyak uang yang masuk dan keluar dari rekening bank mereka. Namun, pengguna dapat menjadi ragu dan khawatir jika notifikasi bank terlambat dikirim melalui SMS. Menurut penelitian yang dilakukan oleh Rahman [3], banyak pengguna mengeluh tentang keterlambatan SMS bank untuk memberikan notifikasi transaksi. Ini menciptakan celah yang dapat dimanfaatkan oleh penipu untuk mengelabui pelanggan dengan membuat *screenshot* yang menunjukkan bukti pembayaran palsu. Akibatnya, diperlukan tindakan untuk meningkatkan keamanan dan kecepatan informasi transaksi perbankan.

Salah satu cara CNN dapat menyelesaikan masalah semacam ini adalah dengan menemukan dan memfilter *screenshot* bukti pembayaran palsu. CNN telah terbukti sangat efektif dalam pengenalan gambar dan deteksi pola. Menurut Bowo dkk [4] dalam penelitiannya menggunakan CNN untuk mengklasifikasi motif citra batik Solo menunjukkan bahwa CNN berhasil mengenali motif pada citra batik yang belum pernah dilihat sebelumnya dengan tingkat akurasi yang tinggi. Penelitian tersebut juga menyebutkan bahwa CNN dapat mempelajari fitur-fitur penting dari citra secara otomatis. Teknologi CNN dapat diintegrasikan ke dalam sistem perbankan untuk memungkinkan pemindaian otomatis pada *screenshot* bukti pembayaran pengguna. Hal ini akan meningkatkan kepercayaan pelanggan terhadap sistem perbankan digital dan mengurangi kemungkinan penipuan transaksi bank. Dalam artikel ini, kami akan membahas lebih lanjut tentang bagaimana CNN digunakan untuk menemukan penipuan transaksi bank dengan melihat *screenshot* bukti pembayaran di sebuah Bank di Indonesia, yaitu Bank Rakyat Indonesia (BRI).

Penelitian ini akan melihat bagaimana CNN dapat meningkatkan keamanan transaksi, khususnya tentang penipuan yang berkaitan dengan pengguna yang tidak terbiasa dengan teknologi, penggunaan *mobile banking* yang rendah, dan keterlambatan pemberitahuan SMS bank.

II. KAJIAN TERKAIT

Kami menemukan bahwa CNN telah banyak digunakan dalam penelitian tentang deteksi gambar, walaupun penelitian yang kami lakukan tidak menemukan penelitian yang secara khusus menyelidiki topik ini. Penelitian sebelumnya telah menunjukkan bahwa CNN berhasil mengenali pola dan fitur gambar untuk deteksi dan identifikasi. Hal ini diungkapkan oleh Indolia dkk [5], bahwa CNN sangat penting untuk deteksi gambar karena dapat secara otomatis mempelajari fitur-fitur penting dari gambar dan mengenali objek dengan sangat akurat. CNN juga dapat mengatasi masalah pengenalan gambar seperti variasi pose, ukuran, dan orientasi. Selain itu, CNN dapat digunakan untuk segmentasi gambar, yaitu memisahkan objek dari latar belakangnya. Oleh karena itu, CNN sangat berguna dalam aplikasi pengenalan gambar seperti deteksi wajah, deteksi kendaraan, dan deteksi objek lainnya.

Kelebihan terkait CNN ini juga dibahas oleh Krizhevsky [6] yang dalam penelitiannya ingin meningkatkan kinerja sistem pengenalan objek dengan menggunakan kumpulan data besar, yakni ImageNet berisi 15 juta gambar beresolusi tinggi dan berlabel di lebih dari 22.000 kategori. CNN dalam hal ini mencapai kinerja canggih dengan tingkat kesalahan yang jauh lebih baik dibandingkan *state-of-the-art* sebelumnya. Hal ini juga dibahas oleh Alizadeh dan Fazel [7] dalam penelitiannya yang menunjukkan tingginya akurasi dalam pengenalan ekspresi wajah menggunakan CNN pada dataset CK+ yang berisi tujuh kategori ekspresi wajah. CNN juga mampu mencapai tingkat akurasi yang sangat tinggi dalam pengenalan dan deteksi gambar pada dataset MNIST (terdiri dari 70.000 gambar digit tulisan tangan) dan CIFAR-10 (terdiri dari 60.000 gambar berwarna dengan resolusi 32x32 piksel).

Kami juga menemukan bahwa CNN telah menjadi metode yang populer untuk mendeteksi penipuan di berbagai bidang, seperti keuangan dan keamanan digital. Studi sebelumnya telah menggunakan CNN untuk mendeteksi penipuan transaksi seperti penipuan kartu kredit, penjualan, dan *phishing*. Misalnya, pada penelitian Fernandes [8] yang ingin mengatasi masalah keamanan digital terkait dengan manipulasi konten multimedia digital dengan mendeteksi manipulasi gambar digital dari dua skenario yang ada, yakni skenario pertama terdiri dari 280 gambar digital yang telah dimanipulasi dan 280 gambar digital asli, sehingga totalnya adalah 560 gambar digital. Skenario kedua menggunakan seluruh dataset yang terdiri dari gambar digital yang telah dimanipulasi dan gambar digital asli, sehingga totalnya adalah 1.120 gambar digital. Dalam hal ini, teknik CNN berhasil mendeteksi manipulasi gambar digital dengan akurasi yang tinggi,

Dalam hal penipuan penjualan, CNN pernah digunakan dalam penelitian Momeny dkk [9] yang membutuhkan suatu teknologi yang dapat membedakan saffron asli dengan saffron palsu secara cepat, akurat, dan non-destruktif. Saffron merupakan produk berupa bunga kering dari tanaman *Crocus sativus* yang sangat penting dalam industri makanan dan obat-obatan. CNN yang dalam penelitian ini digunakan untuk mempelajari fitur-fitur penting pada gambar saffron dan membedakan antara saffron asli dengan saffron palsu, dapat mencapai akurasi deteksi sebesar 99,5% dan menunjukkan bahwa teknologi CNN dapat menjadi suatu teknologi yang efektif dalam deteksi keaslian saffron.

CNN juga pernah digunakan dalam mendeteksi aktivitas *phishing* pada *website* untuk menganalisis fitur gambar dari *website* yang dijadikan sebagai salah satu fitur dalam model deteksi *phishing* yang diusulkan. Hasil penelitian tersebut

menunjukkan bahwa CNN mencapai kinerja relatif terbaik dalam hal akurasi klasifikasi dengan tingkat 92,55% [10]. Untuk mendeteksi penipuan kartu kredit, Al Balawi dan Aljohani [11] menggunakan CNN sambil meminimalkan jumlah klasifikasi penipuan yang salah. Penelitian ini menggunakan dataset Kaggle yang berisi transaksi kartu kredit yang dilakukan oleh pemegang kartu Eropa selama dua hari pada bulan September 2013 dan CNN mencapai akurasi yang sangat tinggi, yakni lebih dari 99%.


Telah terlihat penelitian-penelitian tentang penggunaan CNN dalam deteksi gambar dan peranannya dalam meningkatkan keamanan digital. Meskipun kami tidak menemukan studi yang secara khusus membahas penggunaan CNN untuk mendeteksi *screenshot* bukti pembayaran di Indonesia dan meningkatkan keamanan transaksi, penelitian sebelumnya telah menunjukkan bahwa CNN dapat mendeteksi berbagai jenis penipuan dalam konteks keuangan dan keamanan digital. Dalam hal ini, CNN telah digunakan secara luas untuk mendeteksi penipuan seperti penipuan kartu kredit, *phishing*, dan penipuan penjualan. Penelitian ini memberikan landasan teoritis dan keberhasilan sebelumnya dalam menggunakan CNN untuk mendeteksi penipuan.

Namun, perlu diingat bahwa belum ada penelitian yang secara khusus menyelidiki penggunaan CNN untuk menemukan *screenshot* bukti pembayaran palsu dan meningkatkan keamanan transaksi di Indonesia. Penelitian kami akan mengisi celah ini dengan menggunakan CNN untuk menemukan *screenshot* bukti pembayaran palsu dan membedakannya dari bukti pembayaran asli. Kami berharap penelitian kami akan meningkatkan keamanan transaksi di Indonesia dan memberikan kontribusi baru di bidang ini.

III. METODOLOGI

A. DESAIN PENELITIAN

Gambar 1. menunjukkan arsitektur sistem kerja yang menggambarkan bagaimana proses penelitian dilakukan, yakni dalam hal mendeteksi *screenshot* bukti pembayaran palsu dan yang sebenarnya pada dataset bukti pembayaran menggunakan pendekatan CNN.



Gambar 1. Arsitektur Sistem Kerja

B. DATA COLLECTION

Penelitian ini mengumpulkan data gambar dalam bentuk *screenshot* bukti pembayaran aslidan bukti pembayaran palsu dari beberapa sosial media (Instagram, Twitter, Facebook) dan *search engine* seperti Google. Data yang dikumpulkan adalah bank BRI serta jenis transaksi yang terjadi. Pengumpulan bukti pembayaran ini terfokus pada gambar *screenshot* bukti pembayaran transaksi perbankan yang jelas tanpa coretan

berwarna lain untuk menghindari bias dalam melakukan deteksi gambar, baik bukti yang sebenarnya maupun palsu.

Bukti palsu diambil dari berbagai *screenshot* gambar pembayaran bank yang disertai keluhan pengguna perbankan yang telah terkena tipu daya transaksi *online* palsu. Jika dilakukan pengecekan, uang transaksi tidak masuk ke dalam rekening korban. Sedangkan untuk data bukti yang sebenarnya didapatkan dari pengumpulan data secara kolektif perorangan yang telah melakukan transaksi atau berasal dari suatu instansi yang telah melakukan transaksi jual beli *online* secara sukses.


C. DATA PRE-PROCESSING

Dalam tahap *data pre-processing*, untuk mendeteksi gambar *screenshot* dari bukti pembayaran yang sebenarnya dan palsu dilakukan pemberian label pada gambar dengan label *fake* dan *real* serta penambahan fitur nama bank. Kemudian data tersebut dilakukan *cropping* dan *resize pixel* menjadi ukuran seragam yang sesuai untuk dilakukan *input* pada model. Setelah ukuran data menjadi seragam, dilakukan pemisahan dataset menjadi 3 bagian yaitu data pelatihan (*training data*), data validasi (*validation data*), dan data pengujian (*testing data*) yang mana data validasi diambil dari 20% data pelatihan.

D. PRE-TRAINED MODEL

Model CNN yang telah dilatih pada dataset yang cukup besar dalam klasifikasi gambar, disebut sebagai *pre-trained*. *Pre-trained* sering dilakukan dengan menggunakan dataset yang cukup besar, seperti ImageNet, yang mencakup jutaan gambar yang diberi label dalam berbagai kategori. Selama *pre-trained*, model belajar mengenali berbagai objek, bentuk, dan pola dalam gambar. Kedalaman dan arsitektur *pre-trained model* dapat bervariasi tergantung pada model spesifik yang digunakan. Pada penelitian ini digunakan model EfficientNet-B1 karena dengan parameter 5.3 juta didapatkan hasil Top-1 *Accuracy* 79,1% dan Top-5 *Accuracy* 94,4% yang mana parameter tersebut lebih sedikit tetapi Top-1 *Accuracy* dan Top-5 *Accuracy* lebih tinggi daripada DenseNet-264 dengan parameter 34 juta serta Top-1 *Accuracy* 77,9% dan Top-5 *Accuracy* 93,9% [12]. Sehingga dari penelitian tersebut kami memilih EfficientNet-B1 sebagai *pre-trained model* karena bekerja lebih baik dengan parameter yang lebih sedikit sehingga waktu yang dibutuhkan untuk komputasi tidak terlalu lama.

Bataineh dkk [13] membahas terkait empat jenis lapisan utama yang digunakan untuk membangun arsitektur CNN yang meliputi *convolutional layer*, *ReLU layer*, *pooling layer*, dan *fully connected*. Gambar 2 mengilustrasikan arsitektur umum CNN yang terdiri dari beberapa lapisan. Lapisan ini masing-masing memiliki fungsi spesifik dalam mengubah gambar masukan menjadi sekumpulan probabilitas kelas. Gambar masukan pertama-tama diproses oleh sekumpulan *convolutional layer*, diikuti oleh *ReLU layer* untuk nonlinier, dan *pooling layer* untuk menurunkan sampel peta fitur. Terakhir, *fully connected* digunakan untuk mendapatkan probabilitas kelas.



Gambar 2. Ilustrasi Arsitektur CNN

E. HYPERPARAMETER

Learning rate adalah *hyperparameter* yang mengatur seberapa sering bobot model diubah selama pelatihan. Ini mengontrol seberapa cepat atau lambat model menyerap informasi baru dari data pelatihan. *Hyperparameter* penting yang berdampak besar pada proses pelatihan dan keefektifan model adalah *learning rate*. *Hyperparameter* penting lainnya dalam pelatihan model *deep learning* adalah *batch size*. *Batch size* menetapkan berapa banyak sampel yang diproses secara bersamaan selama setiap iterasi pelatihan. Konvergensi model, kecepatan pelatihan, dan kebutuhan memori semuanya dapat dipengaruhi dengan memilih ukuran *batch* yang tepat. Besarnya *learning rate* dan *batch size* yang dimasukkan tentu akan berdampak pada hasil proses *deep learning* [14].

F. METRIK EVALUASI

Rao, Gopal, dan Lata [15] menyebutkan bahwa *Confusion Matrix* adalah metrik yang sering digunakan untuk menunjukkan kinerja model klasifikasi berdasarkan sebuah himpunan data test yang mana semua nilai *true*-nya diketahui.

TABEL 1
CONFUSION MATRIX

	Actual Positive	Actual Negative
Predicted Positive	TP	FP
Predicted Negative	FN	TN

Dalam hal ini, *True Positive* (TP) menunjukkan jumlah data yang benar diprediksi sebagai positif (bukti yang sebenarnya) oleh model, *True Negative* (TN) menunjukkan jumlah data yang benar diprediksi sebagai negatif (bukti palsu) oleh model, *False Positive* (FP) menunjukkan jumlah data yang salah diprediksi sebagai positif oleh model, yaitu data yang seharusnya negatif namun diprediksi sebagai positif (kesalahan prediksi positif bukti yang palsu), dan *False Negative* (FN) merupakan jumlah data yang salah diprediksi sebagai negatif oleh model, yaitu data yang seharusnya positif namun diprediksi sebagai negatif (kesalahan prediksi negatif bukti yang palsu).

IV. HASIL DAN PEMBAHASAN

Ini merupakan bagian dari hasil penelitian dari algoritma yang diusulkan untuk mendeteksi bukti pembayaran asli dan palsu dibahas di bagian ini bersama dengan metode CNN. Sampel penelitian dalam penelitian ini menggunakan dataset bukti pembayaran berupa *screenshot mobile banking BRI*. Model dievaluasi menggunakan metrik yang berbeda, termasuk akurasi, *confusion matrix*, *recall*, *presisi* dan *F1-score*.

A. ANALISIS DATA

Terdapat 203 *screenshot* bukti pembayaran yang diberikan label Bukti Palsu dan Bukti Asli. Terdapat 102 bukti pembayaran palsu dan 101 bukti pembayaran asli atau yang sebenarnya seperti yang terlihat pada Tabel 2. Hal ini juga menunjukkan bahwa dataset ini memiliki jumlah data yang seimbang.

TABEL 2
PROPORSI JUMLAH *SCREENSHOT* PALSU DAN ASLI

Bukti Palsu	102
Bukti Asli	101

Table 3 menunjukkan bahwa *screenshot* dengan id 4 disimpan dalam /content/drive/MyDrive/Gemastik/Dataset 1/Bukti Palsu dan ditandai sebagai bukti pembayaran palsu.


TABEL 3
CONTOH TAMPILAN DATA *SCREENSHOT* BUKTI PEMBAYARAN

id	filepath	label
4	/content/drive/MyDrive/Gemastik/Dataset 1/BuktiPalsu	Bukti Palsu

B. LANGKAH PENELITIAN

Dalam penelitian tentang klasifikasi bukti pembayaran palsu ada beberapa langkah kerja yang harus dilakukan. Langkah tersebut mencakup pemilihan fitur, *preprocessing data* untuk melakukan *cropping*, *resize pixel*, dan penajaman gambar. Hal ini dilakukan agar gambar dengan label palsu dapat dengan mudah terdeteksi. *Cropping* yang dilakukan juga akan diarahkan ke bagian tulisan yang paling sering di-*edit* untuk membuat bukti pembayaran palsu, yakni di sebelah kanan dengan *thresholding* sebesar. Gambar 3 menunjukkan *sample* hasil *preprocessing data* yang disimpan dalam *dataframe*.

Data yang telah dilakukan *preprocessing* akan dipisah menjadi 162 *training data* dan 41 *testing data*. *Data training* dan *testing* dilatih menggunakan CNN dengan *library* yang sudah disediakan dalam python. Dari situlah akan dibangun model, dilakukan prediksi, dan melihat hasil kinerja CNN dalam deteksi *screenshot* bukti pembayaran asli dan palsu.



Gambar 3. Sample Setelah Preprocessing

C. PENGUKURAN KINERJA

Dalam klasifikasi bukti pembayaran yang kami lakukan ini, dilakukan pengukuran kinerja algoritma CNN. Tabel 4 menunjukkan bagaimana kinerja algoritma di dataset kami pada bukti pembayaran palsu (dengan label 1) dan bukti pembayaran asli (diberi label 0) dalam hal *precision*, *recall*, dan *F-measure*.

TABEL 4
EVALUASI ALGORITMA CNN

	Precision	Recall	F1-Score
0	0,77	0,40	0,53
1	0,46	0,81	0,59

Dalam tabel tersebut ditunjukkan bahwa dari semua bukti yang diprediksi asli oleh model, 77% dari prediksi ini adalah benar-benar bukti pembayaran asli dan dari semua bukti yang diprediksi palsu oleh model ini, hanya 46% dari prediksi ini adalah benar-benar bukti pembayaran palsu.

Selain itu, model hanya berhasil mengidentifikasi 40% dari semua bukti pembayaran asli yang sebenarnya dan mengidentifikasi 81% dari semua bukti pembayaran palsu yang sebenarnya.


F1-Score memberikan gambaran keseimbangan antara kemampuan model dalam mengidentifikasi bukti asli dengan *precision* yang cukup tinggi tetapi *recall* yang relatif rendah. F1-Score pada bukti palsu menunjukkan bahwa model memiliki keseimbangan yang lebih baik antara presisi dan recall, meskipun masih ada ruang untuk perbaikan.

Di Tabel 5 ditampilkan perbandingan dari hasil akurasi, rata-rata *precision*, rata-rata *recall*, dan rata-rata *F-measure* untuk CNN.

TABEL 5
EVALUASI ALGORITMA CNN

<i>Accuracy</i>	<i>Precision (Avg)</i>	<i>Recall (Avg)</i>	<i>F1-Score (Avg)</i>
0,56	0,62	0,61	0,56

Hal ini menunjukkan bahwa CNN memberikan akurasi sebesar 0,56. Pada Gambar 4 ditunjukkan *confusion matrix* algoritma tersebut.



Gambar 4. Hasil Confusion Matrix Prediksi

Model CNN membuat 10 prediksi yang benar untuk bukti asli dari total 25 sampel uji bukti asli. Jumlah prediksi yang salah untuk bukti asli adalah 15. Model ini juga membuat 13 prediksi yang benar untuk bukti palsu dari total 16 sampel uji bukti palsu, serta jumlah salah prediksi bukti palsu adalah 3.

Hasil klasifikasi tersebut didapatkan karena dilakukannya pengolahan gambar pada setiap gambar dalam dataset. Hal ini

cukup mempengaruhi hasil klasifikasi bukti pembayaran palsu dan asli. Pengolahan gambar yang dilakukan melibatkan beberapa tahapan, yang mencakup perubahan gambar ke dalam format *grayscale*, penajaman (*sharpening*), segmentasi adaptif, pencarian kontur, pemilihan *bounding box* terbesar, *cropping*, dan *resizing*. Gambar-gambar dari dataset diolah untuk meningkatkan kualitas dan mengisolasi area yang penting.

Konversi gambar ke citra *grayscale* dapat meningkatkan kejelasan dan menghilangkan gangguan yang tidak relevan dalam gambar berwarna. Penajaman (*sharpening*) juga diterapkan pada gambar *grayscale*. Ini membantu meningkatkan kejelasan gambar. *Cropping* dilakukan dengan menggeser ke arah kanan dengan menambahkan nilai *x_shift*. Hal ini dilakukan karena bukti pembayaran palsu seringkali dimodifikasi pada bagian kanan gambar.

Segmentasi adaptif digunakan untuk memisahkan area penting (bukti transfer) dari latar belakang menggunakan nilai ambang (*threshold*) yang telah ditentukan, yakni 150. Kami menemukan bahwa nilai ambang 150 memberikan hasil yang memadai untuk tugas segmentasi adaptif yang dilakukan. Kontur diidentifikasi untuk memahami bentuk objek. *Bounding box* dengan luas terbesar dipilih sebagai area bukti transfer, dengan penambahan margin agar tidak memotong informasi penting.

Gambar hasil dipotong berdasarkan *bounding box* yang telah diidentifikasi. Gambar hasil *crop* kemudian di-*resize* ke ukuran yang diinginkan (ditentukan oleh *target_width* = 300 dan *target_height* = 700) menggunakan metode interpolasi *INTER_CUBIC*. Ukuran *target_width* dan *target_height* tersebut dianggap lebih tepat agar tidak terjadi *distorted image*. Distorsi yang dimaksud adalah perubahan proporsi objek atau objek yang terlihat terlalu "pipih" atau "melar" dibandingkan dengan bentuk aslinya. Metode interpolasi *INTER_CUBIC* digunakan untuk menghasilkan kualitas gambar yang lebih baik ketika melakukan peningkatan ukuran (*upscaling*) dibandingkan dengan metode interpolasi lainnya.

V. PENUTUP

A. KESIMPULAN

Meskipun kemajuan teknologi telah membuat transaksi perbankan digital lebih mudah, ada peningkatan risiko penipuan melalui *screenshot* yang menunjukkan bukti pembayaran palsu. Penipuan ini mengakibatkan kerugian finansial dan merusak kredibilitas sistem perbankan. Kurangnya pengetahuan digital, terutama bagi orang tua, meningkatkan kemungkinan mereka menjadi korban penipuan. Selain itu, keterlambatan SMS bank memungkinkan penipu membuat *screenshot* palsu. CNN dapat membantu mendeteksi *screenshot* bukti pembayaran palsu untuk mengatasi masalah ini. CNN memiliki kemampuan untuk mem-*filter* gambar dan menemukan pola yang mencurigakan. Studi ini menggunakan CNN untuk meningkatkan keamanan transaksi di bank BRI. Tujuan penelitian ini adalah membangun model CNN yang dapat mendeteksi penipuan pembayaran dan meningkatkan kepercayaan pelanggan dalam sistem perbankan digital.

CNN memiliki akurasi pengujian yang tidak begitu baik dalam deteksi bukti pembayaran palsu. Dalam kasus deteksi bukti pembayaran ini, di mana tahap *preprocessing* menjadi sangat penting dalam meningkatkan akurasi model dalam prediksi. Diharapkan hasil penelitian ini dapat membantu pengembangan algoritma yang lebih baik untuk mendeteksi

bukti pembayaran dan meningkatkan kualitas informasi yang diterima masyarakat.

B. SARAN

Pada penelitian ini, dilakukan percobaan implementasi algoritma CNN dengan melakukan *cropping*, *resize pixel*, dan peningkatan pencahayaan dalam tahap *preprocessing*-nya, tetapi akurasi yang didapatkan masih memerlukan peningkatan. Diharapkan penelitian selanjutnya dapat mengembangkan tahap *preprocessing* untuk meningkatkan akurasi model dalam prediksinya.

REFERENSI

- [1] A. U. Awaliah, "ANALISIS PERAN POLDA DAERAH ISTIMEWA YOGYAKARTA DALAM PENGUNGKAPAN KASUS PENIPUAN JUAL BELI ONLINE," 2021.
- [2] U. Nisa, C. L. C. Nisak, dan D. Fatia, "LITERASI DIGITAL LANSIA PADA ASPEK DIGITAL SKILL DAN DIGITAL SAFETY," *J. Komun. Glob.*, vol. 12, no. 1, hal. 143–167, 2023.
- [3] B. Rahman, "PERTANGGUNGJAWABAN BANK TERHADAP KERUGIAN NASABAH YANG TERKAIT DENGAN FASILITAS TRANSAKSI MELALUI SMS BANGKING," 2016.
- [4] T. A. Bowo, H. Syaputra, dan M. Akbar, "Penerapan Algoritma Convolutional Neural Network Untuk Klasifikasi Motif Citra Batik Solo," vol. 1, no. 2, hal. 82–96, 2020.
- [5] S. Indolia, A. Kumar, S. P. Mishra, dan P. Asopa, "ScienceDirect Conceptual Understanding of Convolutional Neural Network- A Deep Learning Approach," *Procedia Comput. Sci.*, vol. 132, hal. 679–688, 2018, doi: 10.1016/j.procs.2018.05.069.
- [6] A. Krizhevsky dan G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," hal. 1–9.
- [7] S. Alizadeh, "Convolutional Neural Networks for Facial Expression Recognition," no. April, 2017.
- [8] P. A. C. Fernandes, *Benford's law applied to digital forensic analysis*, vol. 45, no. June. 2023.
- [9] M. Momeny, A. Asghar, A. Jahanbakhshi, M. Mahmoudi, Y. Ampatzidis, dan P. Radeva, "Grading and fraud detection of saffron via learning-to-augment incorporated Inception-v4 CNN," *Food Control*, vol. 147, no. May 2022, hal. 109554, 2023, doi: 10.1016/j.foodcont.2022.109554.
- [10] M. Adebawale, K. Lwin, dan A. Hossain, "Intelligent Phishing Detection Scheme Algorithms Using Deep Learning," no. August, 2020, doi: 10.1108/JEIM-01-2020-0036.
- [11] S. Al Balawi, I. Technology, S. Arabia, N. Aljohani, I. Technology, dan S. Arabia, "Credit-card Fraud Detection System using Neural Networks," vol. 20, no. 2, hal. 234–241, 2023.
- [12] M. Tan dan Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," 2019.
- [13] A. Al Bataineh, D. Kaur, M. Al-khassawneh, dan E. Al-sharwa, "Automated CNN Architectural Design: A Simple and Efficient Methodology for Computer Vision Tasks," hal. 1–17, 2023, doi: <https://doi.org/10.3390/math11051141>.
- [14] N. Rochmawati, H. B. Hidayati, dan Y. Yamasari, "Analisa Learning rate dan Batch size Pada Klasifikasi Covid Menggunakan Deep learning dengan Optimizer Adam," vol. 05, hal. 44–48, 2021.
- [15] K. Rao, P. R. Gopal, dan K. Lata, "Computational Analysis of Machine Learning Algorithms to Predict Heart Disease," 2021, vol. 5, hal. 960–964, doi: <https://doi.org/10.1109/Confluence51648.2021.9377185>.